

1. Benchmark / Task

PTB-XL 数据

项目	设置
Dataset	PTB-XL v1.0.3
ECG records	21,799
Patients	18,869
Leads	12
Original sampling rate	500 Hz
Train (Data split)	folds 1–8, 17,418
Validation (Data split)	fold 9, 2,183
Test (Data split)	fold 10, 2,198
Patient overlap	0

all / sub / super 不是三个重新抽样的数据集。
它们使用的是相同 ECG signals、相同 train/val/test split，变化的是分类标签空间

原作者的三种实验模式


Table 3 — Finetuning Encoder 参与训练，会更新，同时下游的 Head 是 Linear Head，看预训练模型经过任务适配后，最高能做得多好	Table 4 — Frozen Encoder 冻结，下游 Head 是 Learnable-query attention head，看 Encoder 不变时配上较强的读取器下游任务能到什么程度	Table 5 — Linear 下游 Head 是单个 Linear Layer，看 Encoder 的特征处理是否具有良好的线性可分性
---	---	--

2. Official Experimental Protocol

项目	Contract
Optimizer	AdamW
Learning rate	1e-3
Weight decay	1e-3
LR schedule	constant
Batch size	64
Epochs	100
Loss	BCEWithLogits
Best checkpoint	highest validation aggregated Macro AUROC
Formal test	best checkpoint
Main metric	record-level aggregated Macro AUROC
Bootstrap	1000 iterations, 95% CI

Independent mode provenance:

Original pretrained checkpoint



保证不同 downstream adaptation strategy 能比较公平

Record-level aggregated Macro AUROC

假设 PTB-XL 有一条完整 ECG: ecg_id = 12345 10 秒 12 leads

但是 ECGFounder 一次只看: 2.5 秒

那 test 时, 一条 10 秒 ECG 会得到多个 window predictions:

ECG 12345

0-2.5 s → 71 个概率

2.5-5 s → 71 个概率

5-7.5 s → 71 个概率

7.5-10 s → 71 个概率

论文规定 test 时把 non-overlapping sliding windows 的预测进行平均

4 个窗口



每个标签 probability 取平均



ECG 12345 最终得到一个 71 维 probability vector

最终每条 ECG 只有一行

ecg_id	label1_prob	label2_prob		label71_prob
12345	0.91	0.03		0.62

同时还有它真正的标签: ground truth: [1, 0, 0, ..., 1]

我们保存的就是: ecg_id + 71 维 predicted probabilities + 71 维 ground truth

Prediction artifact preservation

window-level prediction
record-level aggregated prediction
ground truth target
ECG ID mapping
validation metadata

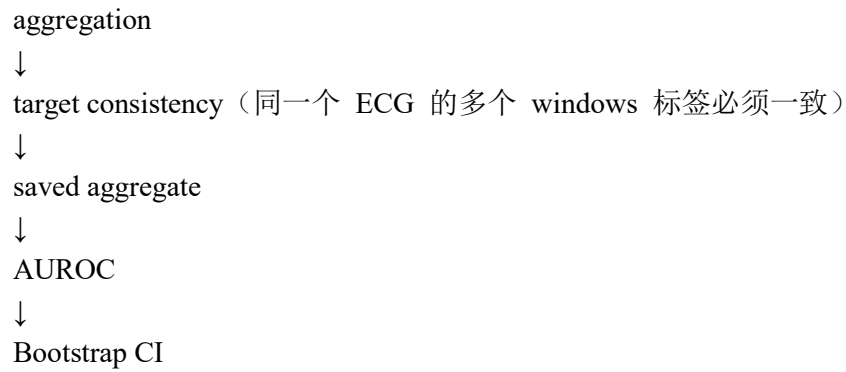
流程:

prediction



ECG ID (每行预测属于哪个真实 ECG)





3. Reproduction Setup

项目采用 locked-code + evidence-driven reproduction 策略

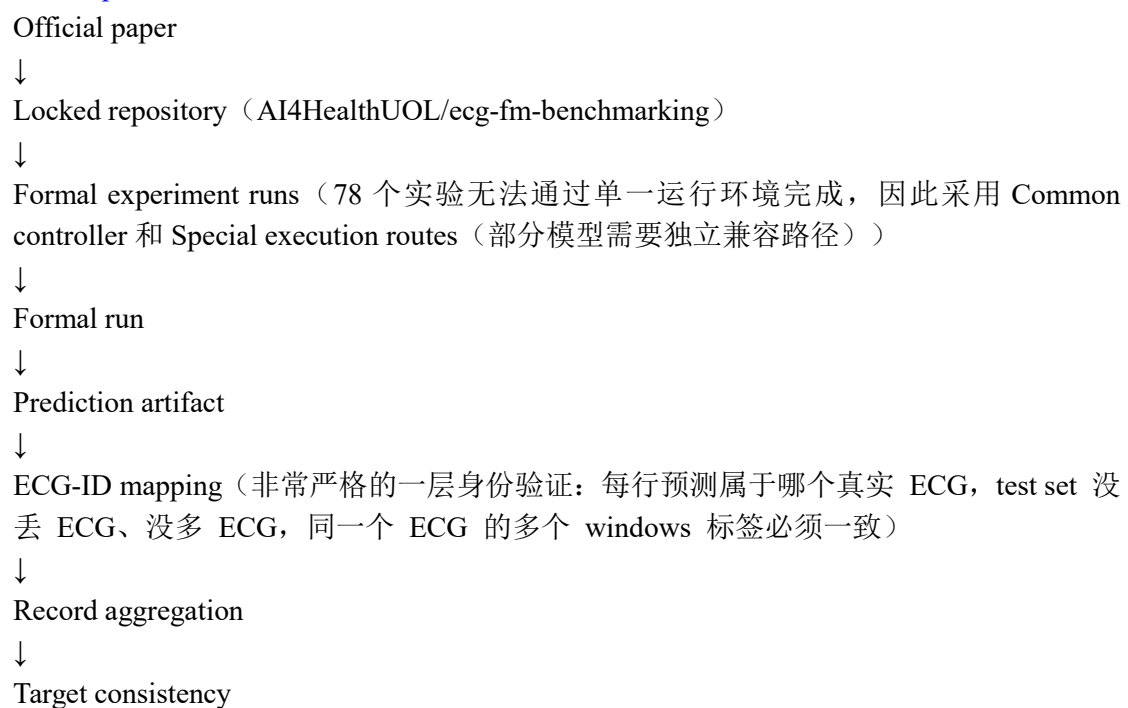
核心原则:

不修改 benchmark scientific protocol;
不通过调参逼近 paper 数值;
不修改 upstream implementation;

所有结果必须以下四点共同支持

official code;
actual runtime logs;
saved predictions;
provenance artifacts

整个 reproduction 分为:



↓
Bootstrap CI
↓
Final table

A significant detail: Frozen / Linear encoder protection

Frozen / Linear 模式要求: pretrained encoder 不更新

但是 PyTorch / Lightning 中: model.train()

不仅代表训练参数, 还会改变模块状态

例如:

BatchNorm→training mode: 更新 running_mean / running_var

即使 requires_grad=False, encoder 状态仍可能变化。

解决:

execution-only BN guard: encoder.eval()

保持 frozen encoder: 参数不更新, BatchNorm statistics 不更新

4. Result and Difference

4.1 Overall Results

本阶段完成了 PTB-XL 上完整的 78-entry reproduction matrix:

Mode	Models	PTB-XL tasks	Entries
Finetuning	8 Foundation Models + S4 + Net1D	all / sub / super	30
Frozen	8 Foundation Models	all / sub / super	24
Linear	8 Foundation Models	all / sub / super	24
Total			78

4.2 Table 3 — Finetuning

4.2.1 Overall Finetuning Reproduction Quality

Statistic	Value
Entries	30
Mean absolute difference	0.005263
Median absolute difference	0.002307
Maximum absolute difference	0.026627
$ \Delta < 0.002$	14/30
$ \Delta < 0.005$	22/30
$ \Delta < 0.010$	26/30

因此 Finetuning 总体是三种 evaluation mode 中平均差异最小的一组

4.2.2 PTB-XL(all)

论文和 reproduction 的最高模型均为:

ECG-CPC: $0.949 \rightarrow 0.948953$, $\Delta = -0.000047$

这是整个实验中复现程度最高的结果之一

4.2.3 PTB-XL(sub)

最佳结果为: ECGFounder: $0.943 \rightarrow 0.941787$

ST-MEM 出现较明显上移:

$0.916 \rightarrow 0.936550$, $\Delta = +0.020550$

这使得 ST-MEM 在我们的 ranking 中从论文中的较后位置提升至较高位置

4.2.4 PTB-XL(super)

最佳模型仍为: ECGFounder: $0.935 \rightarrow 0.934994$, $\Delta \approx -0.000006$

78 个实验中最接近 paper reference 的 entry

ECG-CPC 和 S4 也基本保持 paper 中的高性能位置

ST-MEM 再次出现明显偏高:

$0.901 \rightarrow 0.927627$, $\Delta = +0.026627$

这是 Finetuning 中最大的 reproduction deviation

4.2.5 Finetuning 的主要观察

ST-MEM 的偏差具有明显的 mode-specific consistency:

all: $+0.024892$

sub: $+0.020550$

super: $+0.026627$

但是 ST-MEM 的 Frozen / Linear 并没有出现相同幅度的系统性偏高, 因此该现象更可能需要从 ST-MEM Finetuning execution route 本身进行解释

而不是简单归因于统一 PTB-XL split、metric 或 aggregation pipeline

因为 ST-MEM 历史 execution 中确实经历过:

resampy

sklearn

safetensors

biosppy

transformers

fastai

4.3 Table 4 — Frozen

4.3.1 Overall Frozen Reproduction Quality

Statistic	Value
Entries	24

Mean absolute difference	0.008234
Median absolute difference	0.002000
Maximum absolute difference	0.097321
$ \Delta < 0.002$	12/24
$ \Delta < 0.005$	18/24
$ \Delta < 0.010$	22/24

这里 mean 明显高于 median，说明 Frozen 的整体平均误差同样主要被少量 outlier 拉高

4.3.2 PTB-XL(all)

PTB-XL(all) Frozen 是整个 Frozen 中复现最稳定的一组：

mean absolute difference ≈ 0.002236

max absolute difference ≈ 0.005036

多个模型几乎与论文一致

4.3.3 PTB-XL(sub)

最明显例外是：

ECGFM-KED: $0.816 \rightarrow 0.913321$, $\Delta = +0.097321$

这是 Frozen 表的最大 deviation

4.3.4 PTB-XL(super)

大多数模型同样接近

但 ECGFM-KED 再次明显高于论文：

$0.865 \rightarrow 0.908671$, $\Delta = +0.043671$

4.3.5 Frozen 的主要观察

Frozen 的整体结果不是普遍偏离，而是：

大部分模型高度接近 paper，较大的误差高度集中在 ECGFM-KED 的 sub/super setting

尤其值得注意的是：

ECGFM-KED all Frozen: $\Delta \approx +0.0021$

ECGFM-KED sub Frozen: $\Delta \approx +0.0973$

ECGFM-KED super Frozen: $\Delta \approx +0.0437$

因此该现象明显依赖 label granularity，而不是 ECGFM-KED 在所有 PTB-XL Frozen task 上统一偏移

论文的最高 Frozen(all) 模型为 ECG-JEPA (0.934)，而 reproduction 中 ECG-CPC 以 0.933292 略高于 ECG-JEPA 的 0.928964。

因此这里发生了一次小幅 [top-ranking interchange](#)，但整体 ranking 仍高度相似

4.4 Table 5 — Linear

4.4.1 Overall Linear Reproduction Quality

Statistic	Value
Entries	24
Mean absolute difference	0.012568
Median absolute difference	0.001336
Maximum absolute difference	0.133420
$ \Delta < 0.002$	14/24
$ \Delta < 0.005$	18/24
$ \Delta < 0.010$	18/24

这里出现一个非常重要的统计特征：

Linear 的 median absolute difference 是三种 mode 中最低的，但 mean 和 maximum 反而最高。

这意味着：

大多数 Linear reproduction 极其接近 paper，但存在少量非常大的 outlier

4.4.2 PTB-XL(all)

主要 deviation 包括：

ECG-CPC: $0.904 \rightarrow 0.873559$, $\Delta = -0.030441$

ECGFM-KED: $0.706 \rightarrow 0.688632$, $\Delta = -0.017368$

4.4.3 PTB-XL(sub)

最大的 exception 是：

ECGFM-KED: $0.734 \rightarrow 0.867420$, $\Delta = +0.133420$

这是全部 78 个实验中最大的 paper-vs-ours deviation

4.4.4 PTB-XL(super)

ECGFM-KED 再次显著偏高：

$0.802 \rightarrow 0.877109$, $\Delta = +0.075109$

4.4.5 Linear 的主要观察

Linear 的大偏差高度集中：

ECGFM-KED all: -0.017368

ECGFM-KED sub: $+0.133420$

ECGFM-KED super: $+0.075109$

ECG-CPC all: -0.030441

ECG-CPC: Isolated Linear(all) Negative Deviation

ECG-CPC 大多数结果非常接近 paper

ECG-CPC all: -0.030441

当前 evidence 更支持：

这是一个 task $\times$ mode specific discrepancy，而不是 ECG-CPC 模型整体未正确执行

其余大量模型的 difference 接近 10^{-3} 量级。
因此不能简单说：Linear reproduction 最差
更准确的说法是：Linear 的典型 entry 与 paper 最接近，但少数 model/task-specific outliers 比其他模式更大

5. Dataset-Level Comparison

如果按三个 label granularity 汇总全部 mode:

Dataset	Entries	Mean $ \Delta $	Median $ \Delta $	Max $ \Delta $
PTB-XL(all)	26	0.005243	0.002031	0.030441
PTB-XL(sub)	26	0.012597	0.002274	0.133420
PTB-XL(super)	26	0.007433	0.001651	0.075109

表面上 sub 的 mean difference 最大。

但是三个 dataset 的 median 都约为:

0.0017–0.0023

因此 sub 的较高 mean 并不意味着整个 sub pipeline 普遍较差，而主要是被：ECGFM-KED Frozen / Linear 的两个大 outlier 拉高

换句话说:

没有证据显示 label granularity 从 all $\rightarrow$ sub $\rightarrow$ super 会导致所有模型的 reproduction 一致恶化

6. Model-Level Reproduction Stability

如果将每个 Foundation Model 在三个 dataset $\times$ 三种 mode 的 9 个结果放在一起比较，可以看到明显的 model-specific pattern

最稳定的模型：ECGFounder

9 个 entry 的:

mean absolute difference ≈ 0.000660

maximum absolute difference ≈ 0.001300

说明 ECGFounder 在不同 label granularity 和 downstream mode 下都表现出非常高的 reproduction consistency。

ECG-JEPA

mean absolute difference ≈ 0.001716

max ≈ 0.005036

同样总体稳定

MERL 和 HuBERT-ECG:

mean absolute difference 均约 0.0025

也表现出较好的复现一致性。

中等 model-specific deviations

ECG-CPC:

mean absolute difference ≈ 0.0042

整体稳定, 但 PTB-XL(all) Linear 出现 -0.0304 的单一明显 deviation

ECG-FM:

mean absolute difference ≈ 0.0056

主要偏差集中于 Linear all/sub。

最大 model-specific deviations

ST-MEM:

mean absolute difference ≈ 0.0104

主要由三个 Finetuning 结果持续高于 paper 所驱动

ECGFM-KED:

mean absolute difference ≈ 0.0439

明显高于其他模型, 并且最大的偏差集中在:

Frozen sub

Frozen super

Linear sub

Linear super

因此整个 78-entry matrix 中较大的 reproduction deviations 并不是随机分散在全部模型, 而是高度集中于少数 model-specific execution routes。

7. Ranking Consistency

除了 AUROC 的绝对值之外, 还可以比较模型 ranking 是否得到保留

在 3 modes $\times$ 3 datasets 共 9 个 panel 中:

8/9 个 panel 的最佳模型在 paper 和 reproduction 中一致

唯一例外: Frozen(all)

Paper: ECG-JEPA = 0.934, 为最高。

Ours: ECG-CPC = 0.933292, 为最高;

ECG-JEPA = 0.928964。

但这仍属于局部 ranking interchange, 而不是整个 benchmark ranking 被打乱。

8. Bootstrap Confidence Intervals

72 条正式 run 已完成:

1000 iterations

95% CI

ECG record-level Bootstrap

在这 72 条具有 CI 的结果中:

65/72 的 paper point estimate 落在我们 reproduction 的 95% Bootstrap CI 内。
 这里需要谨慎解释：
 这不是严格的“paper 与 ours 统计等价检验”，因为 paper point estimate 本身也有自己的 sampling uncertainty
 但它可以作为 reproduction consistency 的描述性证据

paper point estimate 不落在 ours CI 内的 entry 包括：

Dataset	Model	Mode	Paper	Ours	Ours 95% CI
super	ST-MEM	Finetuning	0.901	0.927627	[0.920875, 0.934488]
all	ECG-JEPA	Frozen	0.934	0.928964	[0.894124, 0.932136]
sub	ECGFM-KED	Frozen	0.816	0.913321	[0.883066, 0.924198]
super	ECGFM-KED	Frozen	0.865	0.908671	[0.900750, 0.916287]
all	ECG-CPC	Linear	0.904	0.873559	[0.844399, 0.878945]
sub	ECGFM-KED	Linear	0.734	0.867420	[0.839034, 0.891690]
super	ECGFM-KED	Linear	0.802	0.877109	[0.867910, 0.885340]

可以看到，这些条目也与 absolute-difference 分析发现的主要 outliers 高度重合

72 / 78 runs 完成 1000-iteration record-level Bootstrap 并得到 95% CI;
 5 runs 保留为 Bootstrap blocker，没有满足要求：必须能够唯一确定“这条 run 的 canonical aggregated prediction 文件 + canonical target 文件”

- PTBXL_ALL_ECGFOUNDER_FINETUNING_FORMAL
- PTBXL_ALL_ECGFOUNDER_LINEAR_FORMAL_RUN_002
- PTBXL_ALL_ECG_CPC_FINETUNING_FORMAL
- PTBXL_ALL_S4_FINETUNING_FORMAL
- PTBXL_ALL_NET1D_FINETUNING_FORMAL

这五条都是 Strict mapping PASS，但是历史目录里存在多个可能的 artifact / 路径记录
 当前 provenance 不足以唯一指定哪个 aggregate-target pair 应作为正式 Bootstrap 输入

9. Prediction Evidence Quality

本 reproduction 的最终结果不仅依赖一个 AUROC 数值，还建立了 sample/record-level prediction evidence chain:

window-level prediction

↓

canonical ECG ID

↓

target alignment

↓

record-level aggregation

↓
saved aggregate verification
↓
Macro AUROC
↓
Bootstrap CI

因此我们可以验证：

prediction row 属于哪一个 ECG；

同一 ECG 的多个 windows 是否被正确归组；

同一个 ECG 的 target 是否一致；

mean aggregation 是否能够重建保存的 record-level prediction；

Bootstrap 是否真正以 2,198 个 ECG records 而不是 window rows 为采样单位。

这一证据链对于后续 cross-model sample-level error analysis 尤其重要，因为未来可以直接以同一个 ECG ID 比较多个模型的 prediction，而不是比较无法确认身份的匿名 prediction arrays

10. Limitations

1. Historical strict-mapping blocker

PTBXL_ALL_ECGFOUNDER_FROZEN_FORMAL_RUN_001

该 run 的：

formal result 存在 / record aggregation 可以重建 / saved aggregate 可以匹配；

但是 Target consistency 没有达到最高严格标准

TARGET_GROUP_CONSISTENCY=False 表示历史证据不能证明：

分到同一个 ECG group 内的所有 window target vector 完全一致

2. Five Bootstrap provenance blockers

5 条 mapping-PASS run 因 canonical aggregate/target pair 无法唯一定位，没有生成新的统一 Bootstrap CI。

这些条目并不意味着正式 AUROC 或 prediction 已失效，而是 CI provenance 不满足最终统一标准

3. Runtime metadata completeness

部分 sub/super 和 special-route runs 的 finalized table 未保存统一 runtime / best-epoch metadata。

因此本节不使用当前 runtime 字段进行严格的跨模型 computational-efficiency ranking

4. Model-specific large deviations

尤其：

ECGFM-KED Frozen/Linear sub/super

ST-MEM Finetuning
ECG-CPC Linear(all)

存在比其他结果更明显的 paper-vs-ours difference。
这些需要在后面的 Paper vs Ours / Implementation Problems 中结合 model-specific execution route 进一步讨论，不能仅凭数值差异直接归因为 scientific failure。

11.Takeaways

本 PTB-XL reproduction 可以总结为以下几点：

- 完整实验范围已经跑通。
78/78 formal experiments 完成，覆盖三个 label granularities 和三种 downstream evaluation modes
- 大多数结果与论文高度接近。
78 个 comparison 中，58 个 absolute difference < 0.005，66 个 < 0.010；overall median absolute difference 约为 0.00194。
- 主要差异集中于少数模型，而不是统一 pipeline
所有 ($|\Delta| > 0.01$) 的 12 个 entry 只集中在 ECGFM-KED、ST-MEM、ECG-FM 和 ECG-CPC 四个模型，其中 ECGFM-KED 占 6 个

Rank	Dataset	Model	Mode	Paper	Ours	Difference
1	sub	ECGFM-KED	Linear	0.734	0.867420	+0.133420
2	sub	ECGFM-KED	Frozen	0.816	0.913321	+0.097321
3	super	ECGFM-KED	Linear	0.802	0.877109	+0.075109
4	super	ECGFM-KED	Frozen	0.865	0.908671	+0.043671
5	all	ECG-CPC	Linear	0.904	0.873559	-0.030441
6	super	ST-MEM	Finetuning	0.901	0.927627	+0.026627
7	all	ST-MEM	Finetuning	0.908	0.932892	+0.024892
8	sub	ST-MEM	Finetuning	0.916	0.936550	+0.020550
9	all	ECGFM-KED	Linear	0.706	0.688632	-0.017368
10	all	ECGFM-KED	Finetuning	0.889	0.904678	+0.015678
11	sub	ECG-FM	Linear	0.866	0.878925	+0.012925
12	all	ECG-FM	Linear	0.841	0.852464	+0.011464

- ECGFounder 是 reproduction 最稳定的 Foundation Model。
其 9 个正式 comparison 的 mean absolute difference 仅约 0.00066，且 paper/ours 的主排名基本保持一致。
- ST-MEM 的主要 deviation 集中在 Finetuning。
三个 Finetuning task 均明显高于 paper，但 Frozen/Linear 更接近 paper，这提示问

题具有 mode-specific 特征。

- ECGFM-KED 是最明显的 model-specific outlier。
尤其在 sub/super 的 Frozen 和 Linear evaluation 中 reproduction 明显高于 paper，需要作为后续 discrepancy analysis 的重点。
- 整体模型 ranking 大体保留。
9 个 mode $\times$ dataset panels 中，有 8 个 panel 的最佳模型在 paper 与 reproduction 中一致。
- 结果可信度不仅依赖 AUROC 相似。
本项目进一步保存并验证了 prediction、ECG-ID、target、aggregation 和 Bootstrap provenance，使后续 sample-level analysis 有可靠的数据基础。